

Relatório 1 – O que são dados sintéticos?

Fernanda Faria Diniz

Descrição da atividade

Dados sintéticos

Dados sintéticos são dados gerados artificialmente por algoritmos, simulações e modelos estatísticos ou técnicas de aprendizado de máquina para replicar as propriedades e características do mundo real mesmo não sendo coletados diretamente de eventos reais. Quando esses dados são gerados a partir de dados reais, o objetivo é ter novos registros sem correspondência direta com os registros originais. É importante ter atenção para não confundir dados sintéticos com dados falsos, pois os dados falsos são informações genéricas e aleatórias que não necessariamente mantêm a similaridade com a realidade, com as propriedades estatísticas nem com o comportamento do mundo real.

Técnicas para geração de dados sintéticos

Os dados sintéticos podem ser gerados por diferentes abordagens. Em abordagens parcialmente sintéticas, uma parte do conjunto de dados originais é mantida enquanto determinados valores e informações são modificados por meio de ruídos estatísticos ou outras técnicas. Em abordagens totalmente sintéticas, os dados reais são utilizados para construir algum modelo que irá gerar os novos dados sem uma correspondência direta com os dados originais.

Como explicado na definição de dados sintéticos, é possível produzir dados sintéticos por meio de diversas técnicas. De acordo com Kalyan Veeramachaneni, cientista e pesquisador do Schwarzman College of Computing do MIT, o resultado de criar um modelo de aprendizado de máquina generativo a partir de um banco de dados relacional é um novo conjunto de dados sintéticos que, combinado com ruído, preserva os padrões estruturais e estatísticos do original. Um exemplo dessa abordagem é o “Synthetic Data Vault”, desenvolvido por pesquisadores do MIT. Outras maneiras de gerar dados sintéticos além da manipulação de datasets existentes adicionando ruídos ou transformações, são por meio de GANs (Generative Adversarial Networks), por meio de métodos estatísticos e baseados em regras, e vários outros.




Figura 1: Técnicas de geração de dados sintéticos. Fonte: Elaboração própria

Por que os dados sintéticos são utilizados e quais são suas aplicações

Em diversas situações, dados reais podem ser difíceis, caros, insuficientes ou até mesmo conter informações pessoais ou confidenciais, são nesses contextos que surgem a necessidade e a importância dos dados sintéticos, porque eles permitem desenvolver sistemas com menor custo, treinar modelos de aprendizado de máquina com mais dados e consequentemente ter uma melhor precisão, bem como permitem compartilhar dados com menor exposição das informações originais. Além disso, esses dados podem ser produzidos em grande volume, receber rótulos de maneira automática e representar situações raras ou que são pouco observadas nos dados reais.

Alguns exemplos de aplicação são:

- **Saúde:** dados sintéticos para treinar modelos de IA para diagnósticos de imagem protegendo a privacidade dos pacientes ou em simulações de cenários clínicos.
- **Finanças:** dados sintéticos para detectar fraudes e testar aplicações sem divulgar as informações reais e sigilosas.
- **Varejo:** dados sintéticos gerados a partir de simulações para evitar transtornos aos clientes, como o exemplo da startup Caper, em que existem lojas inteligentes onde os clientes não precisam esperar nas filas do caixa.
- **Veículos autônomos:** os dados sintéticos podem gerar dados de condições raras para treinar sistemas de visão computacional e automação dos veículos.
- **Desenvolvimento e testes de softwares:** dados sintéticos utilizados para testar aplicações, consultas e sistemas sem a necessidade de registros confidenciais reais.

Limitações e desafios

Os dados sintéticos apesar de terem muitas vantagens não substituem os dados reais pois, dependendo do método utilizado, eles podem reproduzir erros e vieses dos dados reais, deixar de representar acontecimentos inesperados e apresentar diferenças entre o ambiente simulado e o mundo real. Outras limitações são a possibilidade de perder relações importantes entre variáveis, memorizar informações do conjunto de treinamento ou até serem bons estatisticamente mas não ter os resultados adequados para a tarefa almejada. Por esses motivos, a qualidade dos dados sintéticos precisa ser avaliada levando em consideração três pontos principais:

1. **Fidelidade** – referente à semelhança dos dados sintéticos com os dados reais.
2. **Utilidade** – referente ao desempenho dos dados sintéticos em uma determinada aplicação.
3. **Privacidade** – referente ao risco de exposição ou reidentificação de informações.

A FCA (Financial Conduct Authority), junto com o ICO (Information Commissioner's Office) e o Alan Turing Institute, destacam a importância de comparar distribuições, correlações e o desempenho de modelos treinados com dados reais e sintéticos antes de utilizar esses dados em aplicações práticas.

Dificuldades

Sem dificuldades nessa atividade.

Conclusões

Os dados sintéticos são informações geradas artificialmente para reproduzir padrões e características relevantes do mundo real, podendo ser úteis em diversas áreas como saúde e finanças, principalmente quando os dados reais são caros, sigilosos ou escassos, porém os dados sintéticos não substituem os dados reais. Por isso, é fundamental reconhecer as limitações, avaliar em relação a qualidade, utilidade, fidelidade e privacidade e buscar reduzir cada vez mais os riscos relacionados aos vieses, relações entre as variáveis e à representação da realidade.

De todo modo, a utilização dos dados sintéticos tende a crescer cada vez mais com o avanço contínuo da inteligência artificial e, quando utilizados de forma adequada, irão gerar resultados importantes e úteis no cenário da tecnologia.

Referências

IBM TECHNOLOGY. **What is synthetic data? No, it's not "fake" data**. YouTube, 29 mar. 2023. Disponível em: <https://www.youtube.com/watch?v=HlusawrGBN4>. Acesso em: 20 jul. 2026.

ANDREWS, Gerard. O que são dados sintéticos? Blog da NVIDIA, 20 jul. 2021. Disponível em: <https://blog.nvidia.com.br/blog/o-que-sao-dados-sinteticos>. Acesso em: 20 jul. 2026.

EASTWOOD, Brian. What is synthetic data — and how can it help you competitively? MIT Sloan, 23 jan. 2023. Disponível em: <https://mitsloan.mit.edu/ideas-made-to-matter/what-synthetic-data-and-how-can-it-help-you-competitively>. Acesso em: 21 jul. 2026.

CABALLAR, Rina Diane; STRYKER, Cole. Geração de dados sintéticos. IBM Think, [s.d.]. Disponível em: <https://www.ibm.com/br-pt/think/insights/synthetic-data-generation>. Acesso em: 21 jul. 2026.

FINANCIAL CONDUCT AUTHORITY; INFORMATION COMMISSIONER'S OFFICE; ALAN TURING INSTITUTE. Exploring synthetic data validation: privacy, utility and fidelity. FCA, 12 jun. 2023. Disponível em: <https://www.fca.org.uk/publications/research-articles/exploring-synthetic-data-validation-privacy-utility-fidelity>. Acesso em: 21 jul. 2026.