

Relatório 2 - Aplicações em visão computacional (I)

Fernanda Faria Diniz

Descrição da atividade

Para que modelos de visão computacional sejam capazes de reconhecer objetos, padrões ou até mesmo defeitos em diferentes situações, é necessário ter um grande volume de imagens diversas e corretamente anotadas. Porém, sabemos que a coleta e a rotulagem de dados reais podem ser caras, difíceis, raras ou demoradas, então nesse contexto os dados sintéticos são importantes porque permitem a criação de imagens artificialmente em ambientes virtuais, sendo possível controlar características como iluminação, posição, textura, perspectiva, além de gerar de maneira automática as anotações. Nesse contexto, as ferramentas como NVIDIA Isaac Sim e o Omniverse Replicator ajudam a ampliar e diversificar os datasets, enquanto plataformas como o Roboflow permitem organizar os dados e treinar os modelos. Mas ainda assim, os dados sintéticos devem complementar os dados reais e serem validados em condições reais de aplicação.

Então, no card 2, foram apresentadas essas ferramentas NVIDIA Isaac Sim, Omniverse Replicator e Roboflow, que são um fluxo de trabalho para geração de dados sintéticos em visão computacional se quando usados em conjunto. O Isaac sim é uma ferramenta para criar e simular ambientes virtuais, já o Omniverse Replicator gera imagens sintéticas variadas e anotadas enquanto o Roboflow organiza os datasets, realiza o treinamento e auxilia na avaliação dos modelos.

NVIDIA Isaac Sim e Omniverse Replicator

O NVIDIA Isaac Sim é um ambiente de simulação robótica em que é possível criar cenas virtuais com objetos 3D, sensores, câmeras, iluminação e outras propriedades semelhantes ao mundo real. Dentro desse ambiente, o Omniverse Replicator funciona como uma ferramenta de geração de dados sintéticos, permitindo criar diversas versões de uma mesma cena e controlar os elementos que vão ser modificados em cada execução. Uma das principais técnicas utilizadas é a *Domain Randomization* (randomização de domínio), que altera características como posição dos objetos, cores, perspectiva. O objetivo dessa técnica é expor o modelo a diferentes condições e reduzir a diferença entre o ambiente simulado e o ambiente real, conhecida como *domain gap*. Além de gerar as diversas imagens, o Omniverse Replicator gera automaticamente as anotações correspondentes, como caixas delimitadoras ou máscaras de segmentação. E essas anotações funcionam como referências para o treinamento de modelos de detecção, classificação e segmentação, reduzindo o custo e a demora da rotulagem manual.




Figura 1: Interface do usuário do NVIDIA Omniverse Replicator. Fonte: Synthetic Data Generation with NVIDIA and Roboflow, LYNN (2023)..

Roboflow

O Roboflow é usado para organizar e preparar os dados gerados pelo Omniverse Replicator e ele permite reunir imagens sintéticas e reais, aplicar pré processamento e *data augmentation* (aumento de dados), criar versões dos datasets e preparar os arquivos para o treinamento. Além de possibilitar treinar os modelos e acompanhar métricas de desempenho, avaliando se a combinação entre dados reais e sintéticos melhora os resultados.




Figura 2: Interface do usuário Roboflow. Fonte: Synthetic Data Generation with NVIDIA and Roboflow, LYNN (2023).

Integração entre as ferramentas

Essas ferramentas são utilizadas de maneira sequencial, formando um pipeline de geração e treinamento de modelos de visão computacional. Isso ocorre de modo que, primeiro, o NVIDIA Isaac Sim é usado para criar o ambiente virtual com os objetos e as outras condições da cena, depois o Omniverse Replicator modifica os elementos como posição, iluminação ou outros, gerando diferentes imagens sintéticas com as anotações. Em seguida, as imagens com as anotações são enviadas para o Roboflow, onde podem ser organizadas junto com as imagens reais, receber tratamentos adicionais e formar diferentes versões do dataset e por último tem o treinamento dos modelos e a avaliação do desempenho.

No artigo *Synthetic Data Generation with NVIDIA and Roboflow*, a integração entre o Omniverse Replicator e o Roboflow acontece utilizando a extensão TAA Omniverse Extension, que permite controlar a randomização de domínio por meio de uma interface simples e automatiza o envio das imagens sintéticas com as anotações para o Roboflow, tornando o fluxo de trabalho mais rápido e organizado, reduzindo até a necessidade de transferências manuais ou de algum código de programação para isso.




Figura 3: pipeline de geração e treinamento de modelos. Fonte: Elaboração própria com apoio de inteligência artificial (OpenAI).

Benefícios e desafios

A utilização dessas ferramentas em conjunto, é uma solução para obter grandes volumes de imagens diversificadas e anotadas corretamente para treinar modelos de visão computacional. Por meio de simulações, é possível criar diferentes cenários, contextos, objetos, posições, materiais, perspectiva, iluminações sem a necessidade de coletar esses dados nem rotular manualmente cada imagem, ou seja, elas tornam o processo mais rápido e com menos custos. Outro benefício é a possibilidade de produzir exemplos de situações raras ou difíceis de registrar no mundo real, como falhas em peças, objetos parcialmente ocultos e condições específicas de operação. Então, as imagens sintéticas podem ser organizadas no Roboflow junto com imagens reais, permitindo criar datasets mais diversificados, treinar modelos e acompanhar suas métricas de desempenho. Dessa forma, os dados sintéticos não precisam substituir completamente os dados reais, mas podem complementá-los e ampliar a capacidade de treinamento dos modelos.

Mas, apesar dos benefícios, um dos principais desafios é reduzir a diferença entre o ambiente simulado e o mundo real, conhecida como *sim-to-real gap*. Essa diferença pode ocorrer na aparência dos objetos, nas texturas, nos materiais, na iluminação, na quantidade de elementos e na organização das cenas. Quando o modelo é treinado apenas com situações específicas do ambiente virtual, ele pode aprender características que não se repetem nas imagens reais e apresentar baixo desempenho fora da simulação.

Um estudo sobre *sim-to-real* treinou um modelo YOLOv4 utilizando dados sintéticos com randomização de domínio para detectar objetos industriais. Quando avaliado em 190 imagens reais, o modelo alcançou 86,32% de mAP50 sem utilizar imagens reais no treinamento. Ao adicionar apenas uma imagem real de cada classe, o resultado aumentou para 97,38% de mAP50. Isso mostra que os dados sintéticos podem reduzir a necessidade de grandes volumes de imagens reais, mas que uma pequena quantidade de dados reais pode melhorar a adaptação do modelo ao ambiente de aplicação, portanto, os dados sintéticos devem ser validados e, quando necessário, combinados com dados reais (HORVÁTH et al., 2022).

Dificuldades

Sem dificuldades nessa atividade.

Conclusões

Foi possível aprender que o uso conjunto do NVIDIA Isaac Sim, Omniverse Replicator e Roboflow oferece um fluxo eficiente para a criação, organização e utilização de dados sintéticos em projetos de visão computacional. Que essas ferramentas permitem gerar grandes volumes de imagens variadas e automaticamente anotadas, reduzindo o tempo e os custos da coleta e da rotulagem manual. No entanto, foi visto novamente que, os dados sintéticos não devem substituir completamente os dados reais, pois podem apresentar diferenças em relação às condições encontradas no ambiente de aplicação, portanto, a combinação entre dados sintéticos e reais, acompanhada de testes e validações, é importante para melhorar a adaptação e a confiabilidade dos modelos. Dessa forma, essas ferramentas contribuem para tornar o desenvolvimento de soluções de visão computacional mais rápido, acessível e escalável.

Referencias

NVIDIA. NVIDIA Isaac Sim On Omniverse – Synthetic Data for Perception Model Training. YouTube, 10 jun. 2021. Disponível em: <https://www.youtube.com/watch?v=xsnGhObzOf4>. Acesso em: 24 jul. 2026.

LYNN, Trevor. Synthetic data generation with NVIDIA and Roboflow. Roboflow Blog, 31 mar. 2023. Disponível em: <https://blog.roboflow.com/roboflow-nvidia-omniverse-replicator/>. Acesso em: 24 jul. 2026.

HORVÁTH, Dániel et al. Object Detection Using Sim2Real Domain Randomization for Robotic Applications. IEEE Transactions on Robotics, v. 39, n. 2, p. 1225–1243, 2023. DOI:10.1109/TRO.2022.3207619. Disponível em: <https://ieeexplore.ieee.org/document/9916581>. Acesso em: 24 jul. 2026.