

Relatório 3 - Vantagens e Limitações (I)

Fernanda Faria Diniz

Descrição da atividade

No card 3, o vídeo Synthetic Datasets with Blender Part I faz parte de um conjunto de vídeos sobre a criação de conjuntos de dados de imagens sintéticas. Nesse contexto, o material explica por que a área de visão computacional precisa de um volume tão grande de imagens anotadas, evidenciando as dificuldades de produzir esse tipo de dado no mundo real e apresentando a renderização 3D como uma alternativa viável. Para viabilizar essa abordagem, o vídeo introduz o Blender como uma ferramenta capaz de apoiar a modelagem, a renderização e a automação de cenas destinadas ao treinamento de sistemas de inteligência artificial.

O ponto principal é que os modelos de visão computacional precisam aprender a reconhecer objetos, posições, profundidade e orientações a partir de exemplos práticos. Entretanto, como o processo de reunir e anotar manualmente milhares de imagens exige tempo, recursos e trabalho especializado, é necessário buscar novas metodologias. Diante desse obstáculo, a criação de imagens sintéticas se destaca, visto que permite não apenas controlar as características da cena, mas também produzir inúmeras variações de maneira escalável, incluindo situações raras ou difíceis de serem registradas por meio de fotografias reais.

Blender como ferramenta para geração de dados sintéticos

O Blender é uma ferramenta gratuita e de código aberto para criação 3D que reúne em um mesmo ambiente recursos de modelagem, texturização, iluminação, animação, simulação, renderização, composição e edição de vídeo. Essa centralização de funcionalidades é de grande importância para a geração de dados sintéticos, uma vez que permite construir uma cena virtual completa, definir os objetos de interesse e produzir imagens a partir de diferentes câmeras e condições de iluminação. Além disso, outro diferencial da ferramenta é a possibilidade de automatizar tarefas utilizando scripts Python. Na prática, por meio da API do software, é viável criar objetos, modificar materiais, variar posições, repetir renderizações e organizar os arquivos gerados de forma planejada. Quando aplicados a um pipeline de visão computacional, esses recursos servem para implementar a randomização de domínio, ou seja, a alteração de elementos como cores, texturas, iluminação, escala e composição da cena. Consequentemente, a automação também consegue associar as imagens renderizadas às suas respectivas anotações (como caixas delimitadoras, máscaras de segmentação, mapas de profundidade e orientação), desde que a estrutura de processamento seja previamente configurada para tal fim.

Vale ressaltar, contudo, que o Blender não é a única alternativa para todo e qualquer projeto. Sua maior vantagem, no contexto da geração de dados sintéticos está na combinação entre baixo custo, flexibilidade, ampla integração de recursos 3D e alta capacidade de programação. Por causa desse conjunto de características, é possível criar protótipos ágeis e adaptáveis às necessidades de um objeto ou de alguma aplicação específica.




Figura 1: interface do Blender com integração ao Python. Fonte: Taurino, *Synthetic Datasets for Computer Vision: Complete Guide to Creation with Blender*.

Limitações dos dados reais

Os conjuntos de imagens reais possuem limitações importantes. A primeira delas está relacionada à qualidade das anotações pois como geralmente elas são produzidas por seres humanos, elas estão sujeitas a falhas, podendo conter erros, contornos inconsistentes ou classificações incorretas. Em segundo lugar, tem a falta de especificidade, pois um conjunto disponível publicamente pode não contemplar o objeto, a peça ou a posição exata que uma aplicação precisa reconhecer. Somado a isso, existe a dificuldade de atestar a confiabilidade do conteúdo, pois quando o conjunto de dados é muito extenso, revisar manualmente todas as imagens pode se tornar uma tarefa inviável. Por fim, muitos desses conjuntos oferecem apenas anotações básicas como rótulos, caixas delimitadoras e segmentações, fazendo com que a obtenção de informações mais avançadas como por exemplo de mapas de profundidade, mapas de calor e pose dos objetos, exija um trabalho adicional considerável.

Para contornar essas limitações, os dados sintéticos surgem como uma alternativa promissora. Isso ocorre porque, em uma cena 3D, o sistema possui conhecimento prévio e exato sobre a posição e a identidade dos objetos utilizados na renderização. Como consequência, as anotações podem ser extraídas de maneira planejada e totalmente consistente. Além disso, esse método viabiliza a criação de objetos personalizados, a geração de situações raras e a alteração controlada das condições da cena. Essa abordagem se mostra especialmente vantajosa em cenários em que os dados reais são escassos, de alto custo, perigosos de serem obtidos ou complexos demais para anotações manuais.

Apesar de todos esses benefícios, é importante lembrar que as imagens sintéticas também precisam de validação. Na prática, um conjunto criado com pouca variabilidade pode falhar em representar a diversidade do ambiente físico, induzindo o modelo a aprender características que não se sustentarão durante a aplicação real. Por essa razão, a construção da cena virtual deve considerar com cuidado os objetos, contextos, posições, materiais e condições de iluminação que o sistema irá enfrentar. Diante desse cenário, a combinação estratégica entre dados sintéticos e reais desponta como uma solução equilibrada para aumentar a diversidade do treinamento, sem abandonar as nuances e as características do mundo real.




Figura 2: Imagens reais da xícara e imagens sintéticas renderizadas em 3D. Fonte: Kelly, 2020, *Synthetic Datasets with Blender, Part I*

Vantagens e aplicações

A principal vantagem dos conjuntos sintéticos é a possibilidade de produzir um grande volume de imagens com controle sobre o processo de geração. Em vez de fotografar cada situação fisicamente e desenhar as anotações de forma manual, é possível modificar a cena virtual e renderizar novas imagens sob demanda. Esse processo facilita a criação de exemplos complexos, tais como objetos parcialmente ocultos, em diferentes posições, variações de iluminação e de fundo, além de situações que seriam raras ou muito caras de se registrar no mundo real. Outro benefício significativo é a especificidade do método. Por exemplo, se uma empresa precisa treinar um modelo para reconhecer um componente industrial proprietário, ela pode modelar esse elemento em 3D e inseri-lo diretamente na cena. Além disso, o conjunto de dados pode ser atualizado com relativa facilidade, por exemplo, se surgir uma nova classe de objeto ou condição específica, basta adicionar ao pipeline para que as imagens sejam geradas novamente. Nesse sentido, as aplicações dessa técnica são diversas, abrangendo áreas como robótica, veículos autônomos, inspeção industrial, detecção de defeitos, reconhecimento de objetos e sistemas voltados à estimativa de profundidade ou pose.

Para mostrar o potencial dessa tecnologia, o vídeo utiliza os efeitos visuais de Hollywood como uma analogia intuitiva. Em uma produção clássica com tela verde, elementos que não existem no ambiente físico de filmagem podem ser criados em 3D e, posteriormente, combinados com as imagens reais por meio de composição digital. Um exemplo citado é o de um dragão em uma cena de *Game of Thrones*, que demonstra que uma imagem artificial pode se tornar muito convincente desde que seja construída com modelos e composição adequados. Embora esse cenário seja de entretenimento, ele ajuda na compreensão de porque imagens renderizadas sinteticamente possuem qualidade suficiente para treinar sistemas de visão computacional.

Contudo, na prática, alcançar os melhores resultados não depende exclusivamente do volume de imagens sintéticas geradas, mas sim de um balanço entre a qualidade e a variabilidade inseridas na cena. Por esse motivo, é altamente recomendável avaliar o desempenho do modelo utilizando imagens reais e sempre que possível adotar uma abordagem híbrida que combine ambos os tipos de dados. Em suma, essa estratégia permite aproveitar a escala e a precisão das anotações automatizadas proporcionadas pela simulação, ao mesmo tempo em que garante o contato essencial com as imperfeições, ruídos e variações inerentes ao ambiente real de aplicação.

Dificuldades

Sem dificuldades nessa atividade.

Conclusões

O vídeo mostra que conjuntos de dados de imagens sintéticas podem ajudar a superar dificuldades presentes na coleta e na anotação de imagens reais. Nesse contexto, o Blender se destaca por ser gratuito, completo, flexível e programável, reunindo recursos necessários para criar cenas 3D, renderizar variações e automatizar etapas do processo. Consequentemente, as imagens sintéticas podem ser aplicadas em diferentes áreas, como robótica, inspeção industrial, veículos autônomos e reconhecimento de objetos, especialmente quando há pouca disponibilidade de dados reais ou quando a anotação manual é muito trabalhosa.

Ao mesmo tempo, a criação de um conjunto sintético exige planejamento para que as cenas representem adequadamente as condições do mundo real. Portanto, os dados sintéticos devem ser entendidos como uma forma de ampliar e complementar os dados reais, e não como uma substituição. Desse modo, o desenvolvimento de habilidades que combinem modelagem 3D, programação e inteligência artificial tende a ser relevante para construir soluções de visão computacional mais escaláveis, controláveis e adaptadas a aplicações específicas.

Referencias

KELLY, Adam. Synthetic Datasets with Blender, Part I. YouTube: Immersive Limit, 2020. Disponível em: <https://www.youtube.com/watch?v=M9KVrxlwpO0>. Acesso em: 26 jul. 2026.

BLENDER FOUNDATION. Features. Blender. Disponível em: <https://www.blender.org/features/>. Acesso em: 26 jul. 2026.

TAURINO, Angelo. Synthetic datasets for computer vision: complete guide to creation with Blender. CIM - Competence Center. Disponível em: <https://cim.eu/en/blog/synthetic-datasets-for-computer-vision-a-complete-guide-to-creation-with-blender/>. Acesso em: 26 jul. 2026.