

Relatório 4 - Leitura: Domain gap (I)

Fernanda Faria Diniz

Descrição da atividade

Para desenvolver modelos de visão computacional é necessário grandes conjuntos de imagens anotadas para que o sistema consiga detectar, localizar e segmentar objetos de diferentes situações, entretanto, como já tem sido visto em atividades anteriores, a coleta e a anotação manual desses dados podem exigir muito tempo e custo. Nesse contexto, os dados sintéticos são uma alternativa por permitir criar imagens em ambientes virtuais com variações controladas e anotações geradas automaticamente. Porém, apesar dessas vantagens, um modelo treinado só com imagens sintéticas pode ter dificuldades ao ser aplicado em imagens reais. Essa diferença entre os dois é conhecida como *reality gap* ou lacuna da realidade e pode ser gerado por diferenças de ruído, iluminação, perspectivas e condições do ambiente. Os artigos analisados mostram estratégias que podem reduzir esse problema, especialmente quanto a randomização de domínio e a adaptação de domínio. Então nesse relatório será analisado os trabalhos *Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World* de Tobin et al. (2017), *Training Deep Networks with Synthetic Data: Bridging the Reality Gap by Domain Randomization* de Tremblay et al. (2018) e *Synthetic-to-Real Domain Adaptation for Object Instance Segmentation* de Zhang et al. (2019), analisando como essas técnicas permitem utilizar dados sintéticos em tarefas de visão computacional e seus principais resultados, aplicações, benefícios e limitações na transferência de modelos desenvolvidos em simulação para o mundo real.

A lacuna entre a simulação e o mundo real

Na simulação é possível gerar imagens em grande escala, podendo controlar os cenários, objetos, iluminação, posicionamento da câmera e outros fatores. No entanto, imagens sintéticas não reproduzem completamente as características do ambiente real, pode haver diferenças de textura, sombras, reflexos, ruídos de sensores, perspectiva e organização de objetos que podem fazer com que um modelo identifique padrões presentes apenas na simulação. Essa diferença é conhecida como *reality gap* ou lacuna da realidade, como citado anteriormente. Quando um modelo é treinado somente com dados sintéticos, ele pode aprender a reconhecer elementos específicos do ambiente virtual em vez das características essenciais dos objetos, então, como consequência o desempenho pode diminuir quando passa a analisar imagens reais, mesmo que os objetos sejam semelhantes aos presentes no treinamento.

Além das diferenças visuais, a simulação também pode deixar de representar situações comuns do mundo real, como oclusões, imperfeições, variações de iluminação e diferentes relações entre os objetos. Por isso, usar dados sintéticos exige estratégias que são capazes de aumentar a diversidade das cenas e aproximar o comportamento do modelo com o esperado no ambiente real. Como exemplo dessas estratégias, os artigos apresentam a *domain randomization* (randomização de domínio) e *domain adaptation* (adaptação de domínio) como formas de reduzir esse problema.

Domain randomization (randomização de domínio)

A *domain randomization* é uma técnica que modifica aleatoriamente diferentes elementos das cenas sintéticas durante a geração das imagens. É possível alterar os modelos dos objetos, suas posições e orientações, as texturas, as cores, a iluminação, o cenário, a câmera e a presença de objetos que dificultem a visualização. Dessa forma, o modelo é submetido a uma grande variedade de situações e tende a aprender características mais gerais dos objetos, ao invés de memorizar um ambiente específico.

- **Transferência para tarefas robóticas**

No artigo *Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World* foi analisado se um detector treinado apenas com imagens sintéticas poderia ser usado em um robô real, então, para isso foram criadas cenas virtuais contendo objetos geométricos em diferentes posições, com variações de iluminação, texturas, câmera e objetos de distração. Desse modo, o modelo foi testado em imagens reais capturadas por uma webcam e apresentou erro médio de localização de aproximadamente 1,5cm. Além disso, conseguiu lidar com objetos parcialmente ocultos e com elementos que dificultavam a identificação. O resultado demonstrou que não era necessário reproduzir perfeitamente o ambiente real na simulação e que a ampla variedade de imagens poderia ser suficiente para que o modelo generalizasse para o mundo físico.

- **Deteção de veículos**

No artigo *Training Deep Networks with Synthetic Data: Bridging the Reality Gap by Domain Randomization* essa abordagem foi ampliada para detecção de veículos em imagens reais. Criou-se um conjunto sintético com diferentes modelos de carros, texturas, variações de iluminação, posições de câmera, fundos e objetos de distração e as anotações como as caixas delimitadoras dos veículos foram geradas automaticamente durante o processo de renderização. Nos testes realizados com o conjunto real KITTI, os modelos treinados com dados gerados por *domain randomization* apresentaram desempenho competitivo em relação aos modelos treinados com o Virtual KITTI, que buscava reproduzir visualmente o ambiente real. Além disso, quando o modelo foi pré-treinado com imagens sintéticas e posteriormente ajustado com imagens reais, alcançou AP de 98,5 superando até mesmo os modelos treinados apenas com dados reais. Com isso, é possível ver que os dados sintéticos podem funcionar como uma etapa de pré treinamento e reduzir a quantidade de dados reais necessários.

Domain adaptation (adaptação de domínio)

Enquanto a *domain randomization* aumenta a diversidade das imagens durante a geração de dados, a *domain adaptation* atua durante o treinamento do modelo. Nesse caso o objetivo é aproximar as características aprendidas a partir das imagens sintéticas das características presentes nas imagens reais. Assim, o modelo consegue utilizar dados sintéticos anotados sem depender necessariamente de uma grande quantidade de imagens reais com anotações manuais. No artigo *Synthetic-to-Real Domain Adaptation for Object Instance Segmentation* foi proposto um módulo de adaptação de características, denominado FAM, para a tarefa de segmentação de instâncias, em que esse método utiliza imagens sintéticas anotadas do Virtual KITTI ou do SYNTHIA como domínio de origem e imagens reais do Cityscapes como domínio alvo. As imagens reais utilizadas na adaptação não tinham anotações manuais, o que causa a redução do custo do processo.

O FAM é composto por três módulos, sendo o GFAM que adapta as características gerais da imagem, o LFAM que trabalha com as características locais de cada objeto e por último o SFAM que aproxima as características das máscaras de segmentação. Esses módulos utilizam redes discriminadoras e treinamento adversarial para dificultar a distinção entre características extraídas de imagens sintéticas e reais. Nos experimentos com o Virtual KITTI e o Cityscapes, o método completo alcançou 46,6% de AP50 na segmentação, contra 42,1% do modelo base, representando uma melhoria de 4,5 pontos percentuais. Na detecção, o resultado passou de 46,2% para 52,8% de AP50. Com o SYNTHIA como fonte, o método atingiu 24,8% de mAP na segmentação e 33,2% de mAP na detecção, superando os resultados do modelo sem adaptação. Logo, esses resultados mostram que a adaptação de domínio pode reduzir diferenças que não foram eliminadas durante a geração das imagens sintéticas. Entretanto, a técnica ainda depende da existência de imagens reais representativas do ambiente de aplicação, mesmo que elas não estejam manualmente anotadas.

Na imagem abaixo é possível ver a arquitetura proposta por Zhang et al. (2019), que recebe imagens sintéticas e reais, processa as características por meio de pesos compartilhados e utiliza os módulos GFAM, LFAM e SFAM para reduzir as diferenças entre os dois domínios.




Figura 1: Arquitetura de adaptação de domínio sintético-real para segmentação de instâncias. Fonte: Zhang et al. (2019,

Comparação entre os artigos

Artigo	Objetivo	Estratégia principal	Uso de dados reais	Principal resultado
Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World	Localização de objetos para robótica	Randomização de domínio	Não utilizou imagens reais no treinamento principal	Erro médio de aproximadamente 1,5 cm
Training Deep Networks with Synthetic Data: Bridging the Reality Gap by Domain Randomization	Detecção de veículos	Randomização de domínio e fine-tuning	Utilizou imagens reais para ajuste posterior	AP de 98,5 após o ajuste com dados reais
Synthetic-to-Real Domain Adaptation for Object Instance Segmentation	Segmentação de instâncias	Adaptação de domínio com o módulo FAM	Utilizou imagens reais não anotadas	Melhoria de 4,5 pontos em AP50 na segmentação

A principal diferença entre os dois primeiros trabalhos e o terceiro está no momento em que cada técnica atua. No primeiro e no segundo modificam a aparência e a composição das imagens antes do treinamento, ampliando a diversidade do conjunto sintético. Já no terceiro procuram aproximar as características extraídas das imagens sintéticas e reais durante o treinamento da rede. Os resultados também mostram que não existe uma única solução para superar o *reality gap*. Em alguns casos, a randomização permite transferir diretamente o modelo para o ambiente real e em outros, o melhor desempenho é obtido combinando o pré-treinamento sintético com uma pequena quantidade de dados reais ou utilizando *domain adaptation*. Dessa forma, as

técnicas podem ser utilizadas de maneira complementar, de acordo com a necessidade e com a disponibilidade de dados reais.

Benefícios, aplicações e limitações

Um dos principais benefícios de usar dados sintéticos está na redução do custo de coleta, na geração rápida de grandes volumes de imagens e na criação automática de anotações. Além de também ser possível controlar as condições das cenas e produzir exemplos difíceis de encontrar no mundo real, como objetos parcialmente ocultos, diferentes níveis de iluminação e situações com muitos elementos de distração. Essas características tornam os dados sintéticos úteis em diversas aplicações de visão computacional, que entre elas estão a localização de objetos para robôs, a detecção de veículos, a segmentação de imagens urbanas, os veículos autônomos, a inspeção industrial, os drones e os sistemas de logística automatizada. Nos trabalhos analisados, os dados sintéticos foram utilizados tanto para ensinar um robô a localizar objetos quanto para treinar modelos capazes de detectar veículos e segmentar objetos em cenas reais.

Porém, apesar dos benefícios, as técnicas apresentam limitações. Por exemplo, a criação dos ambientes virtuais pode exigir modelos tridimensionais, configuração de cenários e treinamento de detectores específicos para cada objeto. Além disso, uma randomização insuficiente pode deixar o modelo dependente de determinados padrões da simulação. No artigo *Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World* foi possível ver, por exemplo, que a ausência de objetos de distração prejudicava a detecção de objetos parcialmente ocultos. Outro desafio é que a simulação pode não representar relações presentes no mundo real, como a organização dos veículos em uma rua ou a interação entre diferentes elementos da cena. Já o *Synthetic-to-Real Domain Adaptation for Object Instance Segmentation* mostra que a adaptação de domínio reduz essas diferenças, mas o método exige imagens reais representativas, mesmo que não estejam anotadas, além de aumentar a complexidade do treinamento.

Portanto, os dados sintéticos não devem ser considerados uma substituição automática dos dados reais. O desempenho precisa ser avaliado em imagens do ambiente de aplicação e é melhor combinar randomização, adaptação de domínio e uma quantidade reduzida de exemplos reais para obter modelos mais confiáveis.

Dificuldades

Sem dificuldades nessa atividade.

Conclusões

Os três artigos demonstram que os dados sintéticos podem reduzir significativamente o custo e o tempo necessários para treinar modelos de visão computacional. A *domain randomization* amplia a variedade das cenas simuladas, fazendo com que o modelo aprenda características mais gerais dos objetos, enquanto a *domain adaptation* atua aproximando as representações de imagens sintéticas e reais durante o treinamento. Pelos resultados analisados foi possível ver que modelos treinados em simulação podem ser transferidos para robôs e aplicações reais, especialmente quando são utilizadas variações. Além disso, o pré-treinamento com dados sintéticos junto com poucos dados reais pode superar modelos treinados somente com imagens reais.

No entanto, a simulação não elimina completamente a diferença entre os dois ambientes. A qualidade dos resultados depende da diversidade das cenas, da escolha das técnicas de adaptação e da validação em imagens reais. Assim, a principal contribuição dos artigos é mostrar que a combinação *domain randomization*, *domain adaptation* e dados reais pode tornar o desenvolvimento de sistemas de visão computacional mais escalável, econômico e eficiente.

Referencias

Tobin, Josh, et al. "Domain randomization for transferring deep neural networks from simulation to the real world." 2017 IEEE/RSJ international conference on intelligent robots and systems (IROS). IEEE, 2017.

Tremblay, Jonathan, et al. "Training deep networks with synthetic data: Bridging the reality gap by domain randomization." Proceedings of the IEEE conference on computer vision and pattern recognition workshops. 2018.

Zhang, Hui, et al. "Synthetic-to-real domain adaptation for object instance segmentation." 2019 International Joint Conference on Neural Networks (IJCNN). IEEE, 2019.