

Relatório 9 - Prática: Datasets Sintéticos com Objetos Reais (III)

Fernanda Faria Diniz

Descrição da atividade

A atividade do card 9 teve como objetivo dar continuidade à criação e ao uso de datasets sintéticos. Na primeira frente, foi utilizado um notebook em Python para classificar as imagens sintéticas das letras A, B e C. Na segunda, o mesmo princípio de variação controlada foi adaptado para uma cena 3D de uma caneca de vidro com diferentes níveis de chá. Pulei o vídeo introdutório sobre instalação e uso do Jupyter Notebook pois já tinha instalado no meu computador, além de já saber usar. Seguindo os outros vídeos, foi abordado os conteúdos sobre transferência de aprendizado com TensorFlow Hub e sobre a construção de um cenário no Blender, incluindo materiais, câmera, iluminação, constraints, script e renderização automatizada.

Classificação de imagens

O notebook foi configurado para carregar imagens de 224 por 224 pixels a partir das pastas de treinamento, validação e teste. Foram encontrados, do card 8, 900 exemplos para treinamento, 240 para validação e 30 para teste, distribuídos entre as três classes. Os geradores de imagens fizeram a leitura das pastas e a normalização dos pixels para a faixa entre 0 e 1. Para o modelo, foi utilizado o MobileNetV2 do TensorFlow Hub como extrator de características, mantendo essa parte congelada. Ao final foi adicionada uma camada Dense com ativação softmax e três saídas, uma para cada letra. Essa estrutura caracteriza o uso de transfer learning, em que um modelo pré-treinado é reutilizado e apenas a camada final é ajustada ao novo problema.

O modelo foi compilado com o otimizador Adam, função de perda categorical crossentropy e métrica de acurácia. O treinamento foi executado por 10 épocas, acompanhando simultaneamente os resultados do conjunto de treinamento e do conjunto de validação. Na etapa de inferência, um lote de imagens de teste foi enviado ao modelo e as classes previstas foram comparadas com os rótulos reais. A visualização final permitiu conferir o comportamento do classificador de forma mais concreta, além de mostrar que mesmo um modelo com boa acurácia pode cometer erros em imagens específicas.




Figura 1: inferência do classificador para as letras. As corretas aparecem em verde e as incorretas em vermelho.

Fonte: Captura de tela própria com base no tutorial.

Montagem da cena 3D no Blender

Para a nova geração de dados, foi importado o modelo `tea_mug.fbx`. A cena foi organizada com a caneca de vidro, objetos representando os níveis de chá, um fundo, câmera e iluminação. O material da caneca foi ajustado para preservar a transparência do vidro e o material do chá foi preparado para receber variações de cor.




Figura 2: Cena inicial no com a importação do arquivo `tea_mug.fbx`. Fonte: elaboração própria com base nos tutoriais.

Câmera, constraints e variação do ponto de vista

A câmera foi posicionada com o auxílio de curvas e objetos de controle. Um caminho em arco permitiu variar a altura e o ângulo de observação, enquanto um caminho circular permitiu alterar a posição ao redor da caneca. Constraints do tipo Follow Path, Child Of e Track To foram usados para manter a câmera direcionada ao objeto-alvo.




Figura 3: Configuração do cenário completo. Fonte: elaboração própria com base nos tutoriais.

Automação da renderização com Python

O script foi adaptado para gerar imagens de quatro classes: Full, Half-Full, Mostly-Empty e Empty. A função de rotação altera a caneca no eixo Z, a função da câmera sorteia posições nos dois caminhos e a função de cor varia matiz e saturação do material do chá. O código também alterna a visibilidade dos objetos, define o caminho de saída e salva cada renderização em uma pasta correspondente à sua classe. Para o teste realizado, foi configurada a geração de três imagens por classe no conjunto train, totalizando 12 imagens. Os arquivos foram salvos em PNG e organizados em subpastas, estrutura que permite utilizar o dataset posteriormente em um gerador de imagens ou em um novo treinamento.




Figura 4: Execução do script no Blender, com acompanhamento do progresso.

Fonte: elaboração própria com base nos tutoriais.

Dificuldades

Tive dificuldade no segundo vídeo do Jupyter, porque tive alguns erros com certificado e para configurar o uso do Keras legacy no meu sistema operacional. Mas consegui solucionar.

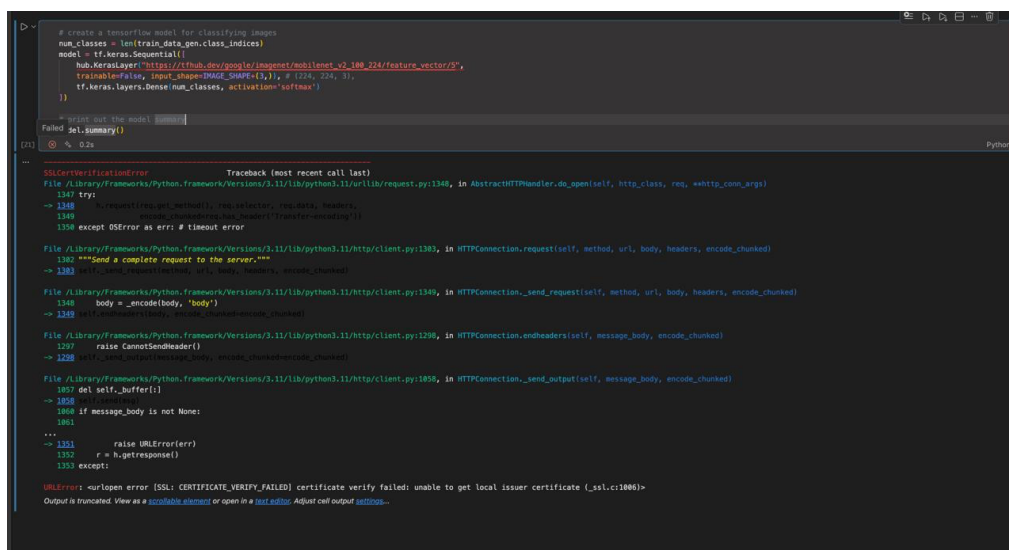


Figura 5: Exemplo de um dos erros. Fonte: elaboração própria.

Conclusões

Com essa atividade foi possível concluir o ciclo entre geração de dados e aprendizado de máquina. O notebook confirmou o funcionamento do classificador por transferência de aprendizado, enquanto o script do Blender ampliou a técnica de dataset sintético para um objeto com estados visuais diferentes. Como continuidade, o conjunto da caneca pode ser ampliado para as pastas val e test e usado no treinamento de um segundo classificador, agora voltado à identificação do nível de chá.

Referencias

KELLY, Adam. Transfer learning classifier. YouTube, s.d. Disponível em: <https://youtu.be/6bK40srQpo4>. Acesso em: 7 ago. 2026.

KELLY, Adam. Criação de ambiente 3D e renderização de dados com Blender. YouTube, s.d. Disponível em: <https://youtu.be/a2YilEIFCvc>. Acesso em: 7 ago. 2026.