

Relatório 11 - Leitura: Introdução a Modelos Generativos e Comparação com Blender (IV)

Fernanda Faria Diniz

Descrição da atividade

No card 11 foram apresentados dois artigos que utilizam *Generative Adversarial Networks* (GANs) para gerar ou aumentar dados sintéticos. O primeiro artigo utiliza uma DCGAN (*Deep Convolutional GAN*) em um cenário com poucos dados para criar imagens de flores e o segundo utiliza uma PGGAN (*Progressive Growing of GANs*) para gerar patches sintéticos e aumentar conjuntos de imagens médicas destinados a segmentação. Em comparação com o Blender, enquanto a geração no Blender parte de uma cena construída explicitamente, uma GAN aprende padrões visuais a partir de exemplos existentes e produz novas amostras por meio de um modelo treinado.

Como funciona uma GAN

Uma GAN é formada por duas redes neurais que aprendem em conjunto, de modo que o gerador recebe um vetor de ruído e tenta transformá-lo em uma amostra semelhante aos dados reais. Já o discriminador recebe imagens reais e imagens produzidas pelo gerador e tenta classificar cada uma como verdadeira ou sintética. Durante o treinamento, o discriminador melhora sua capacidade de identificar imagens artificiais, enquanto o gerador ajusta seus parâmetros para produzir amostras mais convincentes. Por isso o processo é chamado de adversarial porque as duas redes possuem objetivos opostos. O gerador não copia necessariamente uma imagem específica, ele tenta aprender uma representação da distribuição observada no conjunto de treinamento.

Vale destacar que o equilíbrio entre as redes é importante, pois se o discriminador se tornar forte demais, o gerador pode receber um sinal pouco útil e caso o gerador produza amostras muito repetidas, o modelo pode apresentar *mode collapse*, deixando de representar parte da diversidade dos dados. Por isso a qualidade das imagens deve ser observada por inspeção visual e por métricas.




Figura 1: Arquitetura de uma GAN. Fonte: VANDANA; SENTHIL; NARASIMHADHAN (2025)

Geração de flores em um cenário com poucos dados

No primeiro artigo, *Exploring One-Shot GANs for Efficient Synthetic Flower Image Creation*, é implementado uma DCGAN usando *Python* e *TensorFlow*. Embora o título destaque o cenário *one-shot*, o trabalho utiliza um conjunto reduzido de 500 imagens de flores, redimensionadas para 64 x 64 pixels, em que as imagens passam por transformações como rotação, espelhamento horizontal e variação de cor antes do treinamento. A arquitetura possui um gerador e um discriminador convolucionais, onde o gerador começa com um vetor de ruído de 100 dimensões e utiliza convoluções transpostas, normalização em lote e ReLU para ampliar gradualmente a representação até formar uma imagem RGB, enquanto discriminador faz o caminho inverso: reduz a imagem por convoluções e produz uma probabilidade de autenticidade. O treinamento foi realizado durante 250 épocas, com lotes de 32 imagens, utilizando a perda *Binary Cross Entropy* e o otimizador *Adam*. A avaliação usou a *Fréchet Inception Distance* (FID), uma métrica que compara as distribuições de características das imagens reais e sintéticas, nesse caso, valores menores indicam maior proximidade entre as distribuições.

Como resultados principais, o modelo obteve FID de 80,32, enquanto a GAN tradicional usada na comparação obteve 113,06. O artigo interpreta a redução de aproximadamente 29% como um resultado melhor para a DCGAN. A configuração também registrou tempo médio de 47,3 segundos por época e mostrou imagens visualmente plausíveis após 250 épocas.




Figura 2: Imagens de flores geradas usando o modelo One-Shot GAN após 250 épocas.

Fonte: VANDANA; SENTHIL; NARASIMHADHAN (2025)

GANs para aumento de dados médicos

No segundo artigo, *GAN Augmentation: Augmenting Training Data using Generative Adversarial Networks*, é abordado a falta de imagens médicas anotadas. Nesse domínio, a criação de rótulos depende de especialistas e pode ser cara e demorada, então a proposta não é substituir o conjunto real, mas adicionar imagens sintéticas ao treinamento de redes de segmentação. Eles treinam uma PGGAN, com *patches* que contêm simultaneamente a imagem médica e a máscara de segmentação e dessa forma o gerador aprende a distribuição conjunta entre a aparência da imagem e o rótulo correspondente. Depois os patches produzidos são combinados com os dados reais e usados para treinar modelos como *U-Net*, *UResNet* e *DeepMedic*. Foram analisadas duas tarefas, uma foi a segmentação de líquido cefalorraquidiano em imagens de tomografia computadorizada e a outra a segmentação de hiperintensidades da substância branca em imagens de ressonância magnética. O desempenho foi medido pelo *Dice Similarity Coefficient* (DSC), que avalia a sobreposição entre a segmentação prevista e a anotação de referência.

Os resultados indicaram melhorias entre 1 e 5 pontos percentuais em diferentes condições, com efeitos mais fortes quando havia menos de dez volumes de treinamento disponíveis. A combinação de *GAN augmentation* com rotação apresentou ganhos maiores do que cada técnica isolada, mostrando que elas produzem variações complementares.




Figura 3: Exemplos de patches reais e sintéticos gerados por GANs. Fonte:

GANs e Blender

A geração por *Blender* e a geração por GANs não funcionam da mesma maneira. No *Blender* a cena é definida explicitamente, onde o usuário escolhe objetos, materiais, câmeras, iluminação e posições. Como a geometria da cena é conhecida, também é possível obter anotações como máscaras, caixas delimitadoras e profundidade a partir do próprio processo de renderização. Já nas GANs, a cena não é construída diretamente, nesse caso o modelo aprende uma distribuição implícita a partir de dados reais e cria amostras que seguem os padrões aprendidos. Isso reduz a necessidade de modelar manualmente cada variação, mas torna o controle sobre a imagem e sobre a anotação mais indireto. Além disso, a GAN depende de dados de partida, enquanto o *Blender* pode começar com um modelo 3D e regras de simulação.

No entanto as duas estratégias podem ser combinadas. O *Blender* pode gerar cenas controladas e anotações precisas, enquanto uma GAN pode aprender variações de aparência a partir de imagens reais e ajudar a aproximar o resultado do domínio de aplicação. A escolha depende do objetivo, da quantidade de dados reais disponível e do nível de controle necessário.

Limitações e desafios

Os resultados não significam que qualquer imagem gerada por GAN seja automaticamente útil. O modelo pode reproduzir vieses, artefatos ou padrões indesejados presentes no conjunto de treinamento. Em cenários com pouquíssimos exemplos, as imagens podem ficar muito próximas das amostras originais e apresentar pouca diversidade. O segundo artigo também mostra que existe um limite para o benefício, no conjunto de MRI, a adição de dados sintéticos chegou a reduzir o DSC quando todo o volume de dados reais estava disponível. Além disso, a GAN tende a interpolar dentro da distribuição observada, mas não consegue extrapolar de forma confiável para situações fora dos extremos do treinamento. Por isso, transformações tradicionais, como rotação, continuam importantes. Importante ressaltar, como visto em cards anteriores, que a avaliação deve considerar tanto a aparência das imagens quanto a utilidade na tarefa final.

Métricas como FID e DSC ajudam, mas não substituem a inspeção visual, a análise de possíveis artefatos e a validação em dados separados do treinamento. Em aplicações médicas, essa verificação é ainda mais importante porque uma imagem plausível pode conter alterações anatomicamente incorretas.

Dificuldades

Sem dificuldades nessa atividade.

Conclusões

Com os artigos foi possível compreender as GANs como uma alternativa para a geração de dados sintéticos quando existe uma base real que é pequena, pouco diversa ou difícil de anotar. O primeiro artigo mostrou a criação de imagens de flores com uma DCGAN em um cenário de poucos dados, enquanto o segundo demonstrou que imagens geradas podem ampliar o treinamento de modelos de segmentação médica. Também foi possível perceber que as GANs e o Blender resolvem problemas parecidos, mas por caminhos diferentes, em que o Blender oferece controle sobre a cena e facilita a obtenção de anotações, enquanto as GANs aprendem padrões visuais e podem produzir variações sem que cada uma precise ser modelada manualmente. Portanto, as abordagens são complementares e devem ser escolhidas conforme os dados disponíveis, o tipo de aplicação e o nível de controle necessário.

Referencias

VANDANA, S.; SENTHIL, Sugavanam; NARASIMHADHAN, A. V. Exploring One-Shot GANs for Efficient Synthetic Flower Image Creation. In: 2025 International Conference on Artificial Intelligence in Information and Communication (ICAIIIC). IEEE, 2025. p. 0986-0989.

BOWLES, Christopher et al. Gan augmentation: Augmenting training data using generative adversarial networks. arXiv preprint arXiv:1810.10863, 2018.